

Raport: Identyfikacja Podobieństw Zjawisk Meteorologicznych z Wykorzystaniem Metryki Euklidesowej

Filip Pawelec Nr albumu: 197726
Jan Nowosadzki Nr albumu: 198183

29 Czerwiec 2026

1 Opis zadania

Celem naszego projektu jest wyszukiwanie podobieństw pogody i porównywanie danych pogodowych do wybranego dnia wzorcowego. Dane pogodowe pobierane są ze stacji GDN01 za pomocą REST API. Podobieństwo pogodowe mierzone jest za pomocą odległości euklidesowej. Wśród porównywanych parametrów są:

- Temperatura
- Wiatr
- Opady
- Ciśnienie
- Zachmurzenie

2 Kolejność przetwarzania danych

Rozwiązanie zostało podzielone na 5 etapów:

- **Pozyskiwanie danych:** Na początku pobieramy surowe dane z REST API i zapisujemy je do lokalnego pliku JSON.
- **Przetwarzanie danych:** Następnie wyciągane są wielkości, które chcemy porównywać: średnie, minima, maksima.
- **Normalizacja:** Ponieważ np. ciśnienie i opady to zupełnie inna skala, wrzucane są one do StandardScaler'a z biblioteki scikit-learn, aby ujednolicić wartości.
- **Analiza podobieństwa:** Wybieramy dzień wzorcowy i przy pomocy odległości euklidesowej liczymy, które inne dni z naszego zestawu były najbardziej do niego zbliżone pogodowo.
- **Prezentacja wyników końcowych:** Na koniec, przy użyciu matplotlib, generujemy 4 wykresy słupkowe, na których zestawiamy nasz dzień bazowy z trzema najbardziej podobnymi.

3 Miara podobieństwa oparta na odległości

Proces estymacji podobieństwa bazuje na wyliczeniu odległości pomiędzy punktami zawieszonymi w wielowymiarowej przestrzeni znormalizowanych cech.

3.1 Definicja Wektora Cech

Dla każdej analizowanej godziny t tworzony jest wektor reprezentujący stan atmosfery:

$$V_t = [T_{avg}, T_{max}, T_{min}, H_{avg}, W_{max}, P_{avg}, R_{tot}, C_{avg}] \quad (1)$$

gdzie T to temperatura, H to wilgotność, W to prędkość wiatru, P to ciśnienie, R to opady, a C to zachmurzenie.

3.2 Miara Podobieństwa

Stopień podobieństwa pomiędzy wybranym dniem wzorcowym a dniami z historycznego zbioru danych wyznaczany jest na podstawie odległości euklidesowej. Niech V_{ref} oznacza znormalizowany wektor cech dnia referencyjnego, a V_i wektor reprezentujący porównywany dzień. Odległość tę definiuje poniższy wzór:

$$d(V_{ref}, V_i) = \sqrt{\sum_{k=1}^8 (V_{ref,k} - V_{i,k})^2} \quad (2)$$

Wyszukiwanie dni o najbardziej zbliżonych warunkach atmosferycznych sprowadza się do znalezienia obiektów V_i , dla których odległość $d(V_{ref}, V_i)$ przyjmuje najmniejsze wartości.

4 Graficzne przedstawienie wyników

Skrypt analityczny automatycznie generuje wizualizację zebranych danych w formie siatki wykresów o układzie 2×2 . Każdy z paneli odpowiada za inną grupę parametrów meteorologicznych:

- **Wykres lewy górny (Temperatura):** Przedstawia porównanie temperatury średniej, minimalnej oraz maksymalnej.
- **Wykres prawy górny (Opady i wilgotność):** Zestawia dobową sumę opadów oraz średnią wilgotność powietrza.
- **Wykres lewy dolny (Wiatr i zachmurzenie):** Prezentuje maksymalną prędkość wiatru w połączeniu ze średnim zachmurzeniem
- **Wykres prawy dolny (Odległość euklidesowa):** Pokazuje końcowy wynik dopasowania. Stanowi on matematyczny dowód podobieństwa – im niższy słupki na wykresie, tym mniejsza odległość w przestrzeni cech, a co za tym idzie, wyższe pokrewieństwo pogodowe danego dnia do dnia bazowego.




Figure 1: Zestawienie parametrów meteorologicznych

5 Konkluzje i Potencjał Rozwoju

W toku realizacji projektu sformułowano następujące konkluzje architektoniczne i biznesowe:

- Wydajność algorytmiczna:** Wektoryzacja operacji arytmetycznych w bibliotekach takich jak `scikit-learn` gwarantuje szybkie wyliczenie dystansu nawet dla dużych wektorów cech.
- Ograniczona ilość rekordów:** Docelowe środowisko AWS udostępniające logi nakłada narzucony z góry limit 500 rekordów na żądanie. Co w praktyce pozawala na pobranie pogody z maksymalnie 3-4 dni.
- Rozwinięcie projektu** Aby lepiej wykorzystać dane przy obecnym ograniczeniu, lepszą alternatywą byłoby porównywanie pogody godzinowo a nie dniami.